2016 Fall Machine Learning, NTUEE

期末專題報告

林子翔、董皓文、謝秉翰

Section 1 - Team Information

題目：Cyber Security Attack Defender

組別：NTU_b02901080_GottaGetThat

組員：b02901069 林子翔、b02901080 董皓文、r04945025 謝秉翰

分工：

林子翔：進階 model 的設計 (second baseline)、DNN 模型層數與結點數的測試及討論。

董皓文：資料的前處理、特徵值的取出與轉換 (feature engineering)、初始 model 的設計 (first baseline)。

謝秉翰：初始 model 的改良、random forest 跟 support vector machine 的討論。

Section 2 - Preprocessing / Feature Engineering

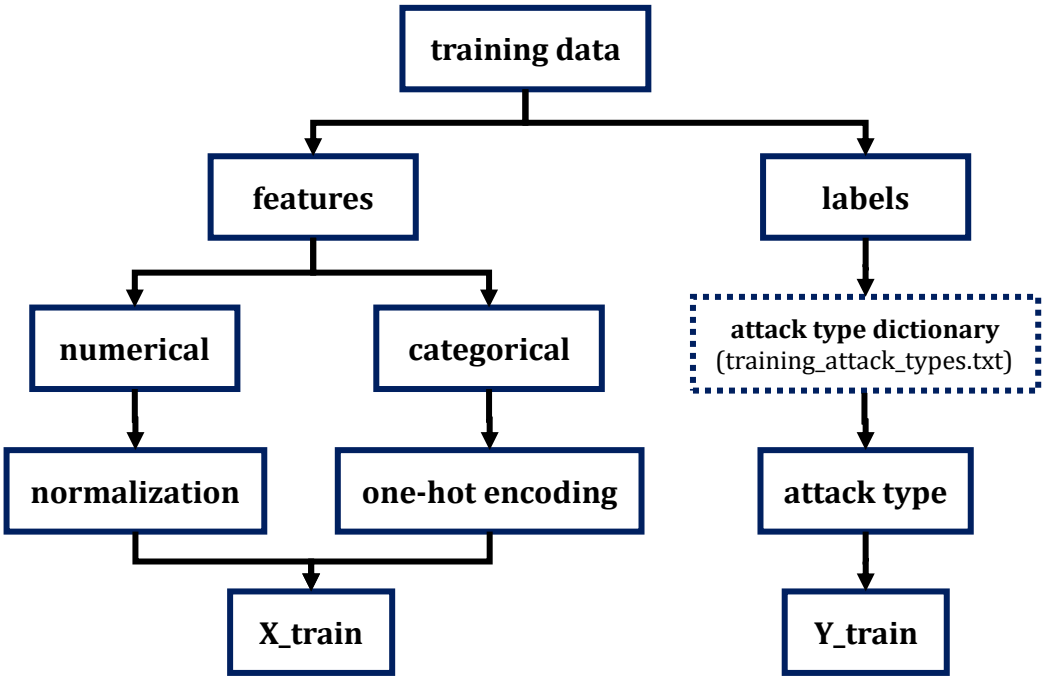

圖一　前處理架構

Step1 - 特徵分類

首先我們按投影片所附特徵資訊表，將特徵分為數值特徵（numerical features）及類別特徵（categorical features），因為兩者所需進行的前處理不同。

由於我們使用的是 DNN 模型，故我們並沒有對 feature 進行篩選，讓 DNN 訓練時自動調整權重。各特徵的重要性在 Section 4 將進一步討論。

在此處我們發現有一個特徵（# of outbound cmd）在所有欄位的值皆為零，不具有用資訊，因此我們先將之移除。

Step2 - 特徵 / 標籤處理

數值特徵（numerical features）

我們對數值特徵進行標準化，使不同特徵不因絕對數值的大小而在 DNN 有先天權重之差異（在 weight 上面特別 dominate）。

類別特徵（categorical features）

我們使用 one-hot encoding 將每個類別特徵轉換為多個 dummy bools，以利後續訓練使用。

標籤（labels）

由於 training data 中的標籤是 attack subtype，我們要進行適當的轉換，才可作為 DNN 的 input。我們先利用 training_attack_type.txt，產生一個 python dictionary，將 subtype 對應到 type（例如 subtype_to_type['apache2'] = 'dos'）。接著再將各個 attack type 編碼成對應的 code（根據題目規定的編碼）。

這裡我們發現 training data 中的資料大多是 DOS 攻擊，為了達到更好的準確度，我們對 DOS 的資料使用 subtype 去進行編碼（即用 apache2, back, mailbomb 等 subtype 作為標籤的意思），在最後產生 test data 的預測類別後，在轉換成對應的 attack type。由於其他三個 type 的攻擊（u2r, r2l, probe）的資料筆數沒有 DOS 多，所以我們沒有用 subtype 下去訓練。這個改變我們從 simple baseline 到 strong baseline 的重要改進。

Step 3 – 完成 X_train 及 Y_train

最後我們將處理過的數值特徵及類別特徵結合成 X_train，而編碼過的標籤作為 Y_train，送到下一階段的 DNN 模型。

Section 3 - Model Description

這邊我們使用了三種不同的演算法：

Deep Learning

我們使用 keras（Theano backend）建立 DNN 模型。我們測試了不同 layer design 的方法（在 Experiments and Discussion 的區域會加以討論），以下是我們最後上傳 kaggle public score 最高的模型架構：

- 四個 hidden layer，node 數量分別為 500, 800, 250, 100，前三層使用 relu 作為 activation function，最後一層使用 sigmoid 產生最終分類。
- 使用 binary cross-entropy 作為 loss function
- 使用 adam（momentum + scaling）的方式更新 gradient descent
- 每一層 hidden layer 後設定 dropout ratio = 0.5，避免 overfitting
- nb_epoch=10、batch_size=5000

Support Vector Machine Classification (SVC)

我們使用 scikit-learn Python package 中的 SVC 物件。在參數的設定上調整不同的 kernel 進行測試，測試的 kernel 有 radial basis function (RBF)、linear、sigmoid 三種。

Random Forest Classification (RF)

我們使用的是 scikit-learn Python package 中的 RandomForestClassifier 物件。在參數的設定上調整不同樹的數量，測試的樹數量有 1000、5000、10000。

演算法比較

為了比較不同演算法的差異，我們這邊將原本的資料隨機取出 1000 個 sample 作為 independent testing set。（因為 kaggle 上的設定一天只能上傳 2 次，且在 deadline 以後就無法上傳了，所以不容易用 public score 有效率的比較不同演算法，因此自己設計 independent testing set。）

接著我們把剩下的資料作為 training set 進行以下分析。對於 Deep Learning 模型，我們自行切割 validation set（隨機取 1/4 的資料），並以 keras 訓練時的 val_acc 監測器做為模型評估的標準。對於 SVM 模型及 RF 模型，我們利用 scikit-learn 進行 4-fold cross validation 來進行模型評估，示意圖如圖二所示。。

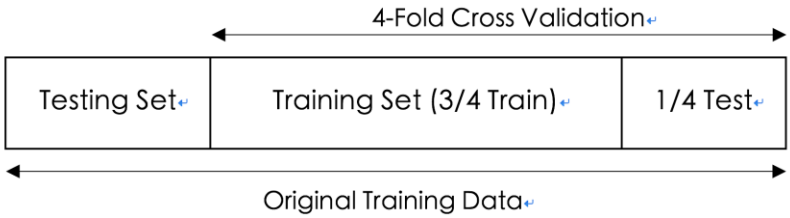

圖二　Training Set 資料分割示意圖

針對上述的三種演算法，我們檢驗了 validation 以及對 testing set 的 score (這邊使用 accuracy 作為評估的依據)，可以得到圖三、圖四結果。

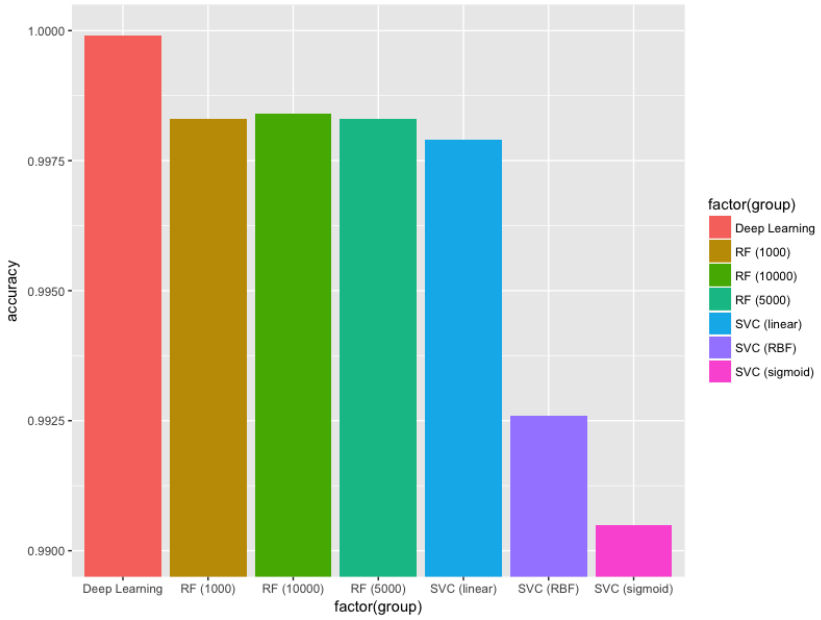

圖三　Validation Set Accuracy 比較

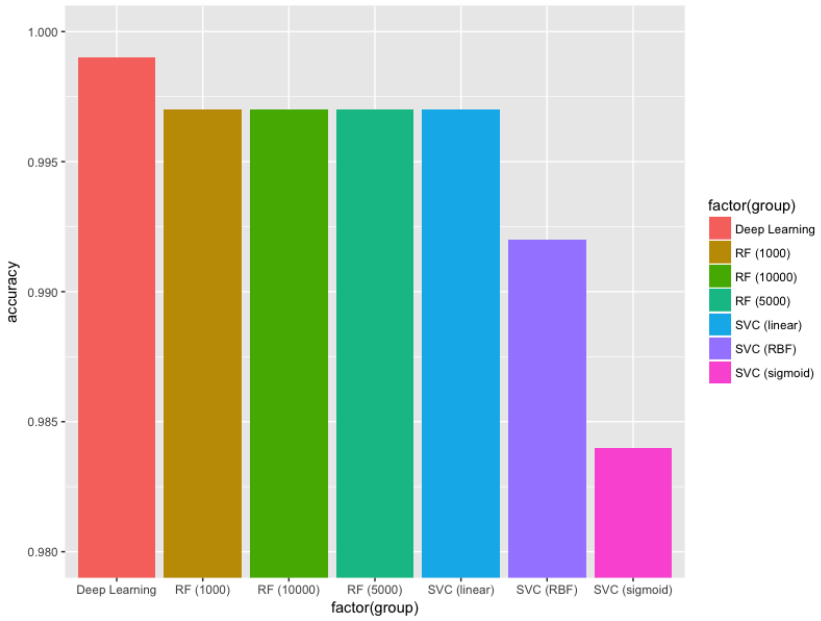

圖四　Testing Set Accuracy 比較

從結果看起來，我們所設計的 DNN model 對於 independent set 或 testing set 的表現都優於其他兩種演算法，因此最後選擇此模型結果上傳 kaggle，在 kaggle public set 得到 **0.96305** 的 accuracy。

Section 4 - Experiments and Discussion

此處為了節省時間以及計算複雜度，我們使用隨機挑選出的 50000 筆 sample 進行討論，並且利用 1/4 的 validation set 以及上述的 1000 筆 independent testing set 進行以下效能討論。

DNN hidden layers 內 node 數量之影響

控制變因：一個 hidden layer（activation function 為 relu）、nb_epoch=10、batch = 5000

操縱變因：hidden layer 之 node 數量

結果：

實驗結果如圖五。可以發現當 node 數量增加時，準確度會提高，但隨著數量超過 100 後，準確度趨緩收斂，數量為 500 時來到 0.985。

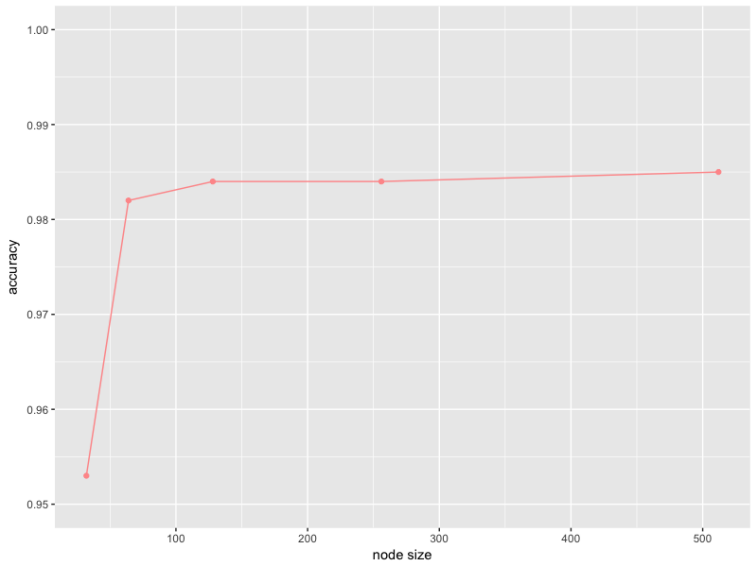

圖五　DNN node 數量對 testing set accuracy 的影響

討論：

DNN 變寬對 accuracy 有顯著的提升，但有其上界，為了突破這個上界，可以加深 DNN 的深度，故我們繼續進行下個實驗。

DNN hidden layers 層數之影響

控制變因：每個 hidden layer 的 node 數為 32（activation function 為 relu）、nb_epoch=10、batch = 5000

操縱變因：hidden layer 層數

結果：

結果如圖六。可以發現越多層 hidden layer 其實並不代表會產生越高的準確度，當 layer 層數越少時反而有更高的 accuracy。

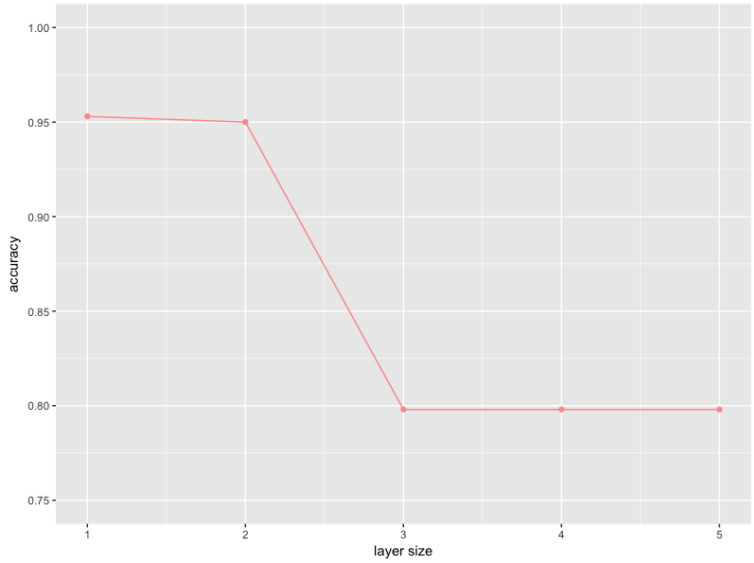

圖六　DNN hidden layers 層數對 testing set accuracy 的影響

討論：

對於這個實驗結果，我想問題可能出在我們的 testing set 切割方式，由於資料中各種類型 attack 分布相當不均，所以 DNN 會嚴重偏向某個類別（例如發現 input 幾乎都是 DNN，就全部都猜 DoS）。

結合上面的 hidden layer 層數（深度）與 node 數量（寬度）的分析，我們可以發現，針對不同的資料，我們需要不同的 DNN 架構，藉由 validation 的過程逐漸調整出最好的架構。調整過程中，發現「上下窄、中間寬」的模型普遍能達到最好的準確度。最後我們選用的是 4 個 hidden layer，所使用的 node 數量分別是 500、800、250、100。

DNN dropout layer 之影響

控制變因：一個 hidden layer（node 數為 32、activation function 為 relu）、nb_epoch=10、batch = 5000

操縱變因：有無 dropout layer（dropout rate = 0.5）

結果與討論：

結果如圖七，可以發現沒有在 DNN 加入 dropout layer 時，在 validation set 的 accuracy 可以達到 0.9962，但是在 testing set 的表現為 0.984。而加入 dropout layer 後，可以觀察到 validation set 的 accuracy 下降為 0.9856，而且在 testing set 的表現為 0.957。由此可見，dropout layer 的確能減少模型 overfitting 的現象，使 validation accuracy 更難反映模型對 test data 的表現，提供修正模型時更正確的參考。

(a)

```
Train on 37500 samples, validate on 12500 samples
Epoch 1/10
37500/37500 [==============================] - 0s - loss: 0.0740 - acc: 0.9854 - val_loss: 0.0605 - val_acc: 0.9884
Epoch 2/10
37500/37500 [==============================] - 0s - loss: 0.0543 - acc: 0.9905 - val_loss: 0.0442 - val_acc: 0.9957
Epoch 3/10
37500/37500 [==============================] - 0s - loss: 0.0401 - acc: 0.9952 - val_loss: 0.0331 - val_acc: 0.9957
Epoch 4/10
37500/37500 [==============================] - 0s - loss: 0.0308 - acc: 0.9953 - val_loss: 0.0260 - val_acc: 0.9959
Epoch 5/10
37500/37500 [==============================] - 0s - loss: 0.0250 - acc: 0.9955 - val_loss: 0.0215 - val_acc: 0.9960
Epoch 6/10
37500/37500 [==============================] - 0s - loss: 0.0213 - acc: 0.9956 - val_loss: 0.0187 - val_acc: 0.9961
Epoch 7/10
37500/37500 [==============================] - 0s - loss: 0.0189 - acc: 0.9958 - val_loss: 0.0168 - val_acc: 0.9965
Epoch 8/10
37500/37500 [==============================] - 0s - loss: 0.0174 - acc: 0.9960 - val_loss: 0.0155 - val_acc: 0.9965
Epoch 9/10
37500/37500 [==============================] - 0s - loss: 0.0162 - acc: 0.9960 - val_loss: 0.0145 - val_acc: 0.9963
Epoch 10/10
37500/37500 [==============================] - 0s - loss: 0.0154 - acc: 0.9958 - val_loss: 0.0137 - val_acc: 0.9962
```

(b)

```
Train on 37500 samples, validate on 12500 samples
Epoch 1/10
37500/37500 [==============================] - 1s - loss: 0.6819 - acc: 0.7315 - val_loss: 0.6618 - val_acc: 0.9184
Epoch 2/10
37500/37500 [==============================] - 0s - loss: 0.6433 - acc: 0.8907 - val_loss: 0.6078 - val_acc: 0.9184
Epoch 3/10
37500/37500 [==============================] - 0s - loss: 0.5738 - acc: 0.9079 - val_loss: 0.5089 - val_acc: 0.9184
Epoch 4/10
37500/37500 [==============================] - 0s - loss: 0.4604 - acc: 0.9144 - val_loss: 0.3686 - val_acc: 0.9184
Epoch 5/10
37500/37500 [==============================] - 0s - loss: 0.3305 - acc: 0.9163 - val_loss: 0.2466 - val_acc: 0.9184
Epoch 6/10
37500/37500 [==============================] - 0s - loss: 0.2381 - acc: 0.9167 - val_loss: 0.1836 - val_acc: 0.9184
Epoch 7/10
37500/37500 [==============================] - 0s - loss: 0.1888 - acc: 0.9175 - val_loss: 0.1452 - val_acc: 0.9184
Epoch 8/10
37500/37500 [==============================] - 0s - loss: 0.1530 - acc: 0.9253 - val_loss: 0.1151 - val_acc: 0.9270
Epoch 9/10
37500/37500 [==============================] - 0s - loss: 0.1263 - acc: 0.9457 - val_loss: 0.0930 - val_acc: 0.9747
Epoch 10/10
37500/37500 [==============================] - 0s - loss: 0.1057 - acc: 0.9631 - val_loss: 0.0759 - val_acc: 0.9856
```

圖七　(a)有 dropout 及(b)沒有 dropout 的 validation accuracy

DNN validation set 之影響

控制變因：三個 hidden layer（node 數為 500、800、100，activation function 為 relu），nb_epoch=10、batch = 5000

操縱變因：validation set =0.2、0.3、0.4、0.5

結果與討論：

我們可以發現：

val set =0.2 時，val_loss: 0.0029、val_acc: 0.9996

val set =0.3 時，val_loss: 0.0015、val_acc: 0. 9997

val set =0.4 時，val_loss: 0.0017、val_acc: 0.9996

val set =0.5 時，val_loss: 0.0036、val_acc: 0.9987

所以我們選擇用 validation set = 0.3 的 model 上傳 kaggle，另外可以觀察到 val set 越大時，要到越後面的 epoch 才會趨於穩定。

DNN batch size 之影響

控制變因：三個 hidden layer（node 數為 500、800、100，activation function 為 relu），validation set=0.3、nb_epoch=10

操縱變因：batch size = 3000、4000、5000、10000

結果與討論：

Batch size = 3000: val_loss: 0.0017、val_acc: 0.9996

Batch size = 4000: val_loss: 0.0018 、val_acc: 0.9997

Batch size = 5000: val_loss: 0.0017 、val_acc: 0.9996

Batch size = 10000: val_loss: 0.0045 、val_acc: 0.9986

可以發現 batch size 太大對 loss 和 accuracy 都不好，至於 batch size 3000 跟 5000 在我們自己的 test data 看不出差異，但是上傳到 kaggle 的分數是 5000 稍微好一些，所以在報告中，我們也選擇 batch size = 5000 來報告。

DNN activation function 之影響

控制變因：三個 hidden layer（node 數為 500、800、100，activation function 為 relu），validation set=0.3、nb_epoch=10、batch size=5000

操縱變因：activation function=relu、sigmoid

結果與討論：

Sigmoid function：loss: 0.1951，val_acc: 0.9476

Relu function：val_loss: 0.0017，val_acc: 0.9996

可以發現明顯在每個 layer 中 relu function 所產生的結果會比 sigmoid 好的多，第一是因為 relu 的運算量比較小且快，第二是因為 relu 在保存資料梯度比 sigmoid 完整(sigmoid 無法反應過大或過小的數字)。所以我們選擇 relu 當作 activation function.

利用 Random Forest 找出重要 features

在測試 random forest 的時候，我們發現 accuracy 表現不差（不論樹的數量為何，表現都相當一致）。並且因為 random forest 演算法是隨機取出 features 並且排列組合決定最能夠區分資料的 features 後，再透過 decision tree 的 ensemble

來進行結果的預測，因此我們推斷這次的 training set 的 features 與 labels 之間的關係是夠直接的，所以以下我們利用 scikit-learn 的 ExtraTreesClassifier 來檢驗 feature 的重要性。得到的結果如下：

```
[  8  18  64  55  19  37  27  24 120  31  38  39  29  90  28  20 116  33
  21  34  30  26  22  35  36  85  23  95  25  32 112  52   1  54   2 115
  60   9   4   6 106   0 121 113  58  84  17  59 114  12  51  44  15 101
 100 117 104  74  79  57  77  80  92  48  89  40 108 105  13  72 107  61
  73  45  83  53  81  70  69  76  63  98  88  94  75  82  97  93  14  10
  46  99  47 110  66  50  78  49  56  71  42 109  87  96 119 111 118   3
   5   7  62  11  16 103 102  68  91  41  43  67  65  86]
```

圖八　所有特徵以重要性高到低排列

對應投影片所附之特徵表，可以發現前五重要的 features 分別為

- number of compromised
- serror rate
- service
- srv serror rate
- dist host rerror rate。

Future Work

- 分析重要性最低的 features 是否不具有用資訊，甚至可能降低準確度
- 各種 attack type 在 training data 中佔的比例相當懸殊，可能造成模型特別偏重某種 attack type。可以嘗試在各個 attack type（甚至是 subtype）都隨機取出相同數量的 data 來訓練 DNN。